

예 상 시 험 문 제

데이터 사이언스 특론 · 1-7주차 · T/F + 단답형 + 코드 + 계산

PART 1

True / False (O/X)

2주차

Python 기본 자료구조

01 T/F

튜플(tuple) 안에 리스트가 있을 때, 그 리스트에 원소를 추가(append)하면 에러가 발생한다.

정답: F (거짓)

해설: 튜플은 "칸(슬롯)"을 고정하는 것이지, 칸 안의 가변 객체(리스트)가 스스로 변하는 것은 막지 않는다. `tup[1].append(3)` 은 가능.

02 T/F

파이썬에서 슬라이싱(slicing)은 범위를 초과하면 IndexError가 발생한다.

정답: F (거짓)

해설: 슬라이싱은 범위 초과 시 있는 만큼만 반환한다. 인덱싱(`s[37]`)이 범위 초과 시 IndexError.

03 T/F

딕셔너리(dict)의 키(key)로 리스트를 사용할 수 있다.

정답: F (거짓)

해설: 딕셔너리 키는 불변(immutable) 객체만 가능. 리스트는 가변이라 `hash()` 불가 → 키로 사용 불가. 정수, 문자열, 튜플은 가능.

04 T/F

`map()` 은 파이썬 내장함수이지만, `reduce()` 는 `functools` 에서 import해야 한다.

정답: T (참)

해설: `map()`, `filter()` 는 내장함수. `reduce()` 는 `from functools import reduce` 필요.

3주차

NumPy

05 T/F

NumPy 배열의 슬라이싱 결과를 수정하면 원본 배열도 함께 변경된다.

정답: T (참)

해설: NumPy 슬라이싱은 View(원본 메모리 공유). 수정 시 원본도 바뀜. 리스트 슬라이싱은 Copy라서 원본 안 바뀜.

06 T/F

Fancy indexing(`arr[[0,3,5]]`)으로 선택한 결과는 원본의 View이다.

정답: F (거짓)

해설: Fancy indexing은 항상 Copy. 비연속적 메모리에서 값을 모아야 하므로 새로운 메모리 블록을 만든다.

07 T/F

`np.nan == np.nan` 의 결과는 True 이다.

정답: F (거짓)

해설: NaN은 자기 자신과 비교해도 항상 False. NaN 확인은 `np.isnan()` 을 사용해야 한다.

08 T/F

`a.sum(axis=0)` 은 행(row) 방향으로 합산하여 행별 합을 반환한다.

정답: F (거짓)

해설: `axis=0` 은 행 축을 사라지게 하면서 합산 → 결과는 열별(column-wise) 합. 행별 합은 `axis=1` .

09 T/F

`shape`이 `(4,3)` 인 배열과 `(4,)` 인 배열은 Broadcasting으로 연산이 가능하다.

정답: F (거짓)

해설: 뒤에서 비교: 3 vs 4 → 불일치. `(4,3) + (3,)` 은 가능(`3==3`). `(4,)` 를 `(4,1)` 로 변환(`np.newaxis`)하면 가능.

4 주 차

Pandas & Matplotlib

10 T/F

`df.dropna()` 는 원본 DataFrame을 직접 수정한다.

정답: F (거짓)

해설: `dropna()` 와 `fillna()` 는 원본 수정 없이 새 DataFrame을 반환한다. 원본 수정하려면 `df = df.dropna()` 또는 `inplace=True` .

11 T/F

Matplotlib의 subplot에서 x축 라벨을 설정할 때 `axes[0][1].xlabel('x')` 를 사용한다.

정답: F (거짓)

해설: subplot에서는 `set_` 접두사를 붙여야 한다: `axes[0][1].set_xlabel('x')` . 단독 `plt.xlabel()` 과 구분 필요.

5 주 차

Tidy Data & 기술 통계

12 T/F

상관계수(correlation coefficient)가 높으면 두 변수 간에 인과관계가 있다고 결론 내릴 수 있다.

정답: F (거짓)

해설: 상관관계 ≠ 인과관계. 인과관계가 있으면 상관관계도 있지만, 상관관계가 있다고 반드시 인과관계가 있는 것은 아니다 (허위 상관).

13 T/F

`melt()` 는 Wide format을 Long format으로 변환하고, `pivot_table()` 은 그 반대이다.

정답: T (참)

해설: `melt()` : Wide→Long (열을 행으로 녹임). `pivot_table()` : Long→Wide (행을 열로 펼침).

6 주 차

확률 & 가설검정

14 T/F

중심극한정리(CLT)에 의하면, 표본 크기가 충분히 클 때 표본 평균의 분포는 모집단의 분포 형태에 관계없이 정규분포에 근사한다.

정답: T (참)

해설: CLT의 핵심: 독립 확률변수의 표본 평균은 $n \geq 30 \sim 50$ 이면 모집단 분포와 무관하게 정규분포에 근사.

15 T/F

가설검정에서 "귀무가설 기각 실패"는 귀무가설이 참이라는 것을 의미한다.

정답: F (거짓)

해설: 기각 실패 = "귀무가설을 기각할 만큼 강력한 증거가 부족하다"는 의미. 귀무가설이 참이라는 증거가 아님. 법정 비유: 무죄 판결 ≠ 결백 증명.

16 T/F

심슨의 역설에서, 전체 데이터에서의 통계적 결론은 항상 하위그룹에서의 결론과 일치한다.

정답: F (거짓)

해설: 혼재변수(confounding variable)로 인해 전체 데이터와 하위그룹에서 결론이 역전될 수 있다. 이것이 심슨의 역설.

7 주 차

p-value · 베이즈 · 경사 하강법

17 T/F

95% 신뢰구간의 올바른 해석은 "진짜 파라미터 p 가 이 구간 안에 있을 확률이 95%이다"이다.

정답: F (거짓)

해설: p 는 고정값이고 구간이 확률적. 올바른 해석: "실험을 반복하면, 만들어지는 구간의 95%에서 진짜 p 가 포함됨."

18 T/F

베이즈 추론에서 사전분포 $\text{Beta}(\alpha, \beta)$ 에 앞면 h 번, 뒷면 t 번을 관측하면 사후분포는 $\text{Beta}(\alpha+h, \beta+t)$ 이다.

정답: T (참)

해설: 이항분포와 베타분포의 켄레 사전분포(conjugate prior) 관계. α 에 앞면 수, β 에 뒷면 수를 더하면 사후분포.

19 T/F

SGD(확률적 경사 하강법)는 Batch GD보다 항상 안정적으로 수렴한다.

정답: F (거짓)

해설: SGD는 데이터 1개씩 업데이트하므로 진동이 심하고 **Gradient Explosion** 위험이 높다. Batch GD가 더 안정적.

20 T/F

경사 하강법에서 learning rate가 너무 크면 발산할 수 있다.

정답: T (참)

해설: lr 너무 크면 → 최솟값을 지나쳐서 진동하거나 발산. 너무 작으면 수렴이 느림.

단답형 · 빈칸 채우기

21 **단답형**

데이터 사이언스의 3가지 구성 요소(벤 다이어그램의 교집합)를 한국어로 쓰시오.

정답: 프로그래밍 실력(Hacking Skills), 수학 및 통계에 관한 지식(Math & Statistics), 도메인 전문성(Substantive Expertise)

22 **단답형**

데이터 과학의 절차 3단계를 순서대로 쓰시오.

정답: 데이터 수집 → 탐색적 데이터 분석(EDA) → 모델링(+예측)

23 **단답형**

NumPy 슬라이싱은 (①)이고, Fancy indexing과 Boolean indexing은 (②)이다.

정답: ① View (원본 공유) ② Copy (독립된 복사본)

24 **단답형**

`axis=0` 은 (①) 축을 사라지게 하면서 연산하여 (②)별 결과를 반환한다.

정답: ① 행(row) ② 열(column)

25 **단답형**

Pandas에서 `merge(how='outer')` 는 두 DataFrame의 (①)에 해당하고, 없는 값은 (②)으로 채워진다.

정답: ① 합집합 ② NaN

26 **단답형**

Tidy Data의 3가지 조건을 쓰시오.

정답: ① 각 변수(variable)는 하나의 열(column) ② 각 관측치(observation)는 하나의 행(row) ③ 서로 다른 관측 단위는 별도의 테이블

27 **단답형**

가설검정에서 "H₀이 참인데 잘못 기각하는 오류"를 (①) 오류라 하고, 확률은 (②)이다.

정답: ① 제1종 (Type I) ② α (유의수준)

28 **단답형**

p-value가 0.03이고 유의수준 $\alpha=0.05$ 일 때, 귀무가설을 (①). 이유: (②).

정답: ① 기각한다 ② $p\text{-value}(0.03) < \alpha(0.05)$ 이므로

29 **단답형**

베이즈 추론에서 빈도주의와 달리 파라미터를 (①)로 취급하며, (②) $\times$ (③)에 비례하여 (④)를 구한다.

정답: ① 확률변수 ② Likelihood(가능도) ③ Prior(사전분포) ④ Posterior(사후분포)

30 **단답형**

경사 하강법의 업데이트 식: $\theta_{t+1} = \theta_t (①) \eta \cdot \nabla f(\theta_t)$. ①에 들어갈 부호와 그 이유는?

정답: ① - (마이너스). 이유: gradient는 함수가 가장 빠르게 증가하는 방향 → 최소값을 찾으려면 그 반대 방향으로 이동해야 하므로.

코드 · 출력 결과

31 코드

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
arr = np.arange(10)
arr_slice = arr[5:8]
arr_slice[1] = 99999
print(arr[6])
```

정답: 99999

해설: NumPy 슬라이싱은 View(원본 공유). arr_slice[1] 은 원본 arr[6] 과 같은 메모리를 가리킨다.

32 코드

다음 코드의 출력 결과를 쓰시오.

```
lst = list(range(10))
lst_slice = lst[5:8]
lst_slice[1] = 99999
print(lst[6])
```

정답: 6

해설: 리스트 슬라이싱은 Copy(독립). lst_slice 를 수정해도 원본 lst 는 변경되지 않는다.

33 코드

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
a = np.array([[1,2],[3,4]])
print(a.sum(axis=0))
print(a.sum(axis=1))
```

정답: [4 6] (axis=0: 열별 합) | [3 7] (axis=1: 행별 합)

34 코드

s = 'abcde' 일 때, s[1:4] , s[::-1] , s[::-2] 의 결과를 각각 쓰시오.

정답: 'bcd' , 'edcba' , 'ace'

35 코드

TB 데이터의 열 이름 new_sp_m04 에서 new_sp_ 접두사를 제거하는 코드를 한 줄로 작성하시오.

정답: tb.columns = [col.replace('new_sp_', '') for col in tb.columns]

36 코드

sex_and_age 열에서 성별(첫 글자)을 추출하여 새 열 sex 를 만드는 코드를 작성하시오.

정답: tb_m['sex'] = tb_m['sex_and_age'].apply(lambda v: v[0])

37 코드

선형 회귀에서 오차 e = predicted - y 일 때, 손실함수 L = e² 의 slope 에 대한 편미분을 쓰시오.정답: $\partial L / \partial \text{slope} = 2e \cdot x$ ($= 2 \times (\text{slope} \cdot x + \text{intercept} - y) \times x$)

계산 문제

38 **계산**

유병률이 0.01%(10,000명 중 1명), 검사 정확도가 99%(양성|질병 99%, 양성|건강 1%)일 때, 양성 판정을 받은 사람이 실제로 병에 걸렸을 확률을 베이즈 정리로 구하시오.

$$\text{정답: } P(D|T) = \frac{0.99 \times 0.0001}{0.99 \times 0.0001 + 0.01 \times 0.9999} = \frac{0.000099}{0.000099 + 0.009999} \approx 0.0098 \text{ (약 0.98\%)}$$

해설: 100만 명 기준: 환자 100명 중 양성 99명(진양성) + 건강한 999,900명 중 양성 9,999명(위양성) → 총 양성 ~10,098명 중 진짜 환자 99명 ≈ 1%

39 **계산**

사전분포가 Beta(20, 20)일 때, 동전을 10번 던져 앞면 3번, 뒷면 7번이 나왔다. 사후분포와 그 평균을 구하시오.

$$\text{정답: 사후분포: Beta}(20+3, 20+7) = \text{Beta}(23, 27) \mid \text{평균} = \frac{23}{23+27} = \frac{23}{50} = 0.46$$

해설: 켈레 사전분포: α에 앞면 수를, β에 뒷면 수를 더함. 사전 평균 0.50에서 데이터(3/10)의 영향으로 0.46으로 이동.

40 **계산**

동전을 1000번 던져 앞면이 530번 나왔다 (H₀: p=0.5). 연속성 보정을 적용한 양측 p-value가 0.062일 때, 유의수준 5%에서 결론을 내리시오.

정답: p-value(0.062) > α(0.05) → 귀무가설 기각 실패. "이 동전이 편향됐다"고 결론 내릴 수 없다.

41 **계산**

관측 비율 $\hat{p} = 0.525$, 표본 크기 $n = 1000$ 일 때, 95% 신뢰구간을 구하고 H₀: p=0.5에 대해 판단하시오. ($z_{0.025} = 1.96$)

$$\text{정답: SE} = \sqrt{(0.525 \times 0.475 / 1000)} \approx 0.0158 \mid \text{CI} = 0.525 \pm 1.96 \times 0.0158 = [0.494, 0.556]$$

0.5가 CI 안에 포함 → 기각 실패

42 **계산**

효과 없는 가설 20개를 동시에 검정할 때, 적어도 1개에서 유의미한 결과(α=0.05)가 나올 확률은?

$$\text{정답: } 1 - (1 - 0.05)^{20} = 1 - 0.95^{20} \approx 1 - 0.358 \approx 0.642 \text{ (약 64\%)}$$

해설: 이것이 p 해킹의 핵심. 여러 가설을 동시 검정하면 거짓인데도 유의미하게 나올 확률이 매우 높아진다.

43 **계산**

두 아이 성별 문제: 딸이 최소 한 명 있을 때, 둘 다 딸일 확률을 조건부 확률로 구하시오.

$$\text{정답: L(최소 1명 딸)} = \{(아들, 딸), (딸, 아들), (딸, 딸)\} \rightarrow P(L) = 3/4$$

$$B(\text{둘 다 딸}) = \{(딸, 딸)\} \rightarrow P(B \cap L) = 1/4$$

$$P(B|L) = \frac{1/4}{3/4} = 1/3$$