

데이터 사이언스 특론 — 예상문제 Final

PART 1 — T/F · OX (25문항)

Q.01

파이썬 리스트의 `sort(key=len)` 은 길이가 같은 원소들의 원래 순서를 유지하는 안정 정렬(stable sort)이다. ()

Q.02

`zip()` 함수에서 두 리스트의 길이가 다르면 긴 쪽에 맞춰 짧은 쪽에 None이 채워진다. ()

Q.03

딕셔너리에서 `in` 연산자는 값(value)이 존재하는지 확인한다. ()

Q.04

`del d[key]` 와 `d.pop(key)` 의 차이점은, `pop()` 은 삭제된 값을 반환하지만 `del` 은 반환값이 없다는 것이다. ()

Q.05

파이썬에서 `('hello')` 와 `('hello',)` 는 모두 튜플이다. ()

Q.06

NumPy 배열의 `Transpose(.T)` 는 원본의 독립적인 복사본(Copy)을 반환한다. ()

Q.07

`shape`이 `(3,)` 인 배열은 "3행 0열"의 2차원 배열이다. ()

Q.08

`np.inf - np.inf` 의 결과는 0이다. ()

Q.09

Boolean indexing에서 여러 조건을 결합할 때 파이썬의 `and`, `or` 대신 `&`, `|` 를 사용해야 한다. ()

Q.10

`data[data < 0] = 0` 은 원본 배열을 수정하지 않는다. ()

Q.11

`shape`이 `(4,3)` 인 배열과 `(3,)` 인 배열은 Broadcasting으로 연산 가능하다. ()

Q.12

`np.radians()` 는 라디안(radian) 값을 도(degree) 값으로 변환한다. ()

Q.13

`df.drop('열이름', axis=1)` 은 원본 DataFrame을 직접 수정한다. ()

Q.14

DataFrame에서 `df.loc['Store 1']` 의 결과는 인덱스 중복 여부와 관계없이 항상 Series 타입이다. ()

Q.15

DataFrame과 Series의 산술 연산에서 라벨이 불일치하면 ValueError가 발생한다. ()

Q.16

Matplotlib subplot에서 x축 라벨을 설정할 때 `axes[0].xlabel('x')` 를 사용한다. ()

Q.17

`df['col'].apply(func)` 는 해당 열의 각 원소에 함수를 적용하여 새 Series를 반환한다. ()

Q.18

`melt()` 는 Long format을 Wide format으로 변환한다. ()

Q.19

상관계수(correlation)는 두 변수 간의 비선형 관계도 정확하게 측정할 수 있다. ()

Q.20

Tidy Data에서 같은 테이블 안에 여러 타입의 observational unit이 있어도 괜찮다. ()

Q.21

표준편차(Standard Deviation)는 분산(Variance)의 제곱이다. ()

Q.22

p-value가 0.03이면 "효과가 있을 확률이 97%"라고 해석할 수 있다. ()

Q.23

경사 하강법에서 learning rate가 너무 작으면 발산(diverge)할 수 있다. ()

Q.24

심슨의 역설은 전체 데이터의 결론이 하위그룹의 결론과 항상 일치함을 의미한다. ()

Q.25

중심극한정리(CLT)에 의하면, 모집단의 분포가 정규분포가 아니어도 표본 크기가 충분히 크면 표본 평균의 분포는 정규분포에 근사한다. ()

PART 2 — 단답형 · 빈칸 채우기 (20문항)**Q.26**

튜플이 불변(immutable)이라 함은, 튜플의 (_____)을 변경할 수 없다는 의미이다. 그러나 내부의 가변 객체가 (_____)하는 것은 가능하다.

Q.27

딕셔너리의 키가 될 수 있는 조건은 (_____) 가능한 객체여야 하며, 딕셔너리가 리스트보다 검색이 빠른 이유는 (_____) 기반 O(1) 검색이 가능하기 때문이다.

Q.28

NumPy 슬라이싱은 (_____)이고, 리스트 슬라이싱은 (_____)이다. NumPy에서 원본을 보호하려면 (_____) 메서드를 사용해야 한다.

Q.29

Broadcasting에서 shape을 비교하는 방향은 (_____)부터이며, 각 차원이 (_____)하거나 둘 중 하나가 (_____)이면 연산 가능하다.

Q.30

Pandas의 `loc` 은 (_____) 기반, `iloc` 은 (_____) 기반 접근이다.

Q.31

`merge(how='outer')` 는 (_____)에 해당하고, `merge(how='inner')` 는 (_____)에 해당한다.

Q.32

Tidy Data의 3가지 조건을 쓰시오.

Q.33

Messy Data의 대표적 유형 3가지를 쓰시오.

Q.34

`melt()` 의 핵심 파라미터: (_____)은 유지할 열, (_____)은 녹인 열이름이 들어갈 열, (_____)은 녹인 값이 들어갈 열이다.

Q.35

상관계수의 범위는 (_____)이며, (_____) 관계만 비교 가능하다.

Q.36

가설검정에서 (_____) 오류는 "효과 없는데 있다고 판단"이고, (_____) 오류는 "효과 있는데 없다고 판단"이다. 검정력(Power)은 (_____)이다.

Q.37

95% 신뢰구간의 올바른 해석: "실험을 반복하면, 만들어지는 구간의 (_____)%에서 진짜 파라미터가 (_____)"

Q.38

경사 하강법의 업데이트 식: $\theta(t+1) = \theta(t) - \eta \cdot \nabla f(\theta(t))$. 빈칸에 들어갈 부호와 그 이유는?

Q.39

데이터 사이언스의 3가지 구성 요소(벤 다이어그램)를 쓰시오.

Q.40

"학점 성적(A>B>C)"처럼 순서가 있는 범주형 변수를 (_____) 변수, "성별(남/여)"처럼 두 가지만 있는 변수를 (_____) 변수라 한다.

Q.41

`axis=0` 은 (_____) 축을 제거하면서 연산하여 (_____)별 결과를 반환한다.

Q.42

`df.describe()` 가 출력하는 통계량 8가지를 쓰시오.

Q.43

베이즈 정리: $P(A|B) = P(B|A) \times (\text{_____}) / (\text{_____})$. $P(A)$ 를 (_____)확률, $P(A|B)$ 를 (_____)확률이라 한다.

Q.44

`groupby()` 의 동작은 (_____) $\rightarrow$ (_____) $\rightarrow$ (_____) 세 단계이다.

Q.45

`plt.axvline(x=550)` 은 그래프에 (_____)선을 그려주며, `plt.hist()` 의 `bins` 는 히스토그램의 (_____)를 지정한다.

PART 3 — 코드 출력 · 작성 · 에러찾기 (20문항)**Q.46**

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
arr = np.arange(15).reshape((3,5))
t = arr.T
t[0][2] = -999
print(arr[2][0])
```

Q.47

다음 코드의 출력 결과를 쓰시오.

```
tup = (1, [10, 20], 'hello')
tup[1].append(30)
print(tup)
```

Q.48

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
a = np.array([[10, 20, 30],
              [40, 50, 60]])
print(a.mean(axis=0))
print(a.mean(axis=1))
```

Q.49

다음 코드의 출력 결과를 쓰시오.

```
data = [3, 1, 4, 1, 5]
result = [x**2 for x in data if x > 2]
print(result)
```

Q.50

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
arr = np.array([1, -2, 3, -4, 5])
arr[arr < 0] = 0
print(arr)
```

Q.51

다음 코드에서 에러가 발생하는 줄과 이유를 쓰시오.

```
import numpy as np
a = np.ones((4, 3))
b = np.array([1, 2, 3, 4])
c = a + b
```

Q.52

다음 코드의 출력 결과를 쓰시오.

```
names = ['a', 'b', 'c', 'd']
scores = [85, 70, 92]
print(list(zip(names, scores)))
```

Q.53

다음 코드의 출력 결과를 쓰시오.

```
s = 'DataScience'
print(s[4:11])
print(s[::-1])
print(s[:3])
```

Q.54

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
a = np.array([[1,2],[3,4]])
print(a.sum(axis=0))
print(a.sum(axis=1))
print(a.sum())
```

Q.55

다음 DataFrame을 `melt()` 로 Tidy Data로 변환하는 코드를 작성하시오.

```
df = pd.DataFrame({'Name': ['Alice', 'Bob'],
                    'Math': [90, 85],
                    'English': [80, 95]})
```

Q.56

다음 코드의 출력을 쓰고, `d1` 과 `d2` 중 더 빠른 `in` 검색을 제공하는 것과 이유를 답하시오.

```
d1 = [i for i in range(10000)]
d2 = {i: i for i in range(10000)}
print(9999 in d1)
print(9999 in d2)
```

Q.57

`sex_and_age` 열에서 성별(첫 글자)을 추출하여 새 열 `sex` 를 만드는 코드를 한 줄로 작성하시오.

Q.58

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
arr = np.arange(10)
arr_slice = arr[5:8]
arr_slice[1] = 99999
print(arr[6])
```

Q.59

다음 코드의 출력 결과를 쓰시오.

```
lst = list(range(10))
lst_slice = lst[5:8]
lst_slice[1] = 99999
print(lst[6])
```

Q.60

일일 궤도수(`n_day`)를 각속도(`n_rad`, rad/s)로 변환하는 코드를 작성하시오. (하루 = 86400초)

Q.61

`df` 의 `calc` 열과 `actual` 열의 차이를 `diff` 열에 저장하고, `describe()` 로 오차 통계를 출력하는 코드를 작성하시오.

Q.62

df['value'] 열의 히스토그램(bins=50)을 그리고, x=100 위치에 빨간 점선을 추가하는 코드를 작성하시오.

Q.63

다음 코드의 출력 결과를 쓰시오.

```
import numpy as np
print(np.nan == np.nan)
print(np.isnan(np.nan))
print(np.inf > 99999999)
```

Q.64

다음 코드에서 에러가 발생하는 줄과 이유를 쓰시오.

```
d = {'a': 1, 'b': 2}
d[[1,2,3]] = 'list_key'
```

Q.65

다음 코드의 출력 결과를 쓰시오.

```
from functools import reduce
nums = [1, 2, 3, 4, 5]
result = reduce(lambda x, y: x + y, nums)
print(result)
```

PART 4 — 계산 문제 (8문항)

Q.66

데이터 [2, 4, 4, 4, 5, 5, 7, 9]의 평균, 분산, 표준편차를 구하시오.

Q.67

유병률 2%(0.02), 검사 정확도(양성|질병) 95%, 오탐률(양성|건강) 10%일 때, 양성 판정자가 실제 환자일 확률을 베이즈 정리로 구하시오.

Q.68

사전분포가 Beta(10, 10)일 때, 동전을 20번 던져 앞면 15번, 뒷면 5번이 나왔다. 사후분포와 그 평균을 구하시오.

Q.69

동전을 500번 던져 앞면이 275번 나왔다. $H_0: p=0.5$, 양측검정, $\alpha=0.05$, 계산된 p-value=0.032일 때, 결론을 내리시오.

Q.70

효과 없는 가설 10개를 동시에 검정($\alpha=0.05$)할 때, 적어도 1개에서 유의미한 결과가 나올 확률은?

Q.71

$X = [1, 2, 3, 4, 5]$, $Y = [2, 4, 6, 8, 10]$ 의 상관계수를 구하시오.

Q.72

두 아이 성별 문제: 최소 한 명이 딸일 때, 둘 다 딸일 확률을 조건부 확률로 구하시오.

Q.73

관측 비율 $\hat{p} = 0.525$, 표본 크기 $n = 1000$ 일 때, 95% 신뢰구간을 구하고 $H_0: p=0.5$ 에 대해 판단하시오. ($z = 1.96$)

Q.74

NumPy 슬라이싱이 View(원본 공유)인 이유를 설명하고, 리스트 슬라이싱과의 차이를 서술하시오.

Q.75

Tidy Data의 3가지 원칙을 쓰고, 열 이름에 값이 들어가 있는 데이터가 Messy인 이유와 해결 방법을 설명하시오.

Q.76

"상관관계가 있으면 인과관계도 있다"는 주장이 왜 틀린지 설명하고, 구체적 예시를 드시오.

Q.77

베이즈 정리에서 "사전확률(Prior)"이 결과에 미치는 영향을 의료 검사 사례를 통해 설명하시오.

Q.78

p-value의 정확한 의미를 설명하고, 흔한 오해 2가지를 바로잡으시오.

Q.79

`apply()` 에서 `lambda`를 쓰는 경우와 사용자 정의 함수를 쓰는 경우를 각각 예시와 함께 설명하시오.

Q.80

`describe()` 를 이용한 오차 검증이 왜 중요한지 설명하고, 계산값과 실제값 사이 오차 발생 원인을 1가지 이상 제시하시오.

ANSWER KEY — 정답 및 해설

PART 1 정답

- Q.01 T. Timsort 기반 안정 정렬. 같은 key면 원래 순서 유지.
- Q.02 F. zip()은 짧은 쪽에 맞춰 끊긴다. None 채우기는 itertools.zip_longest().
- Q.03 F. in은 키(key) 확인. 값은 in dict.values().
- Q.04 T. pop()은 삭제된 값 반환. del은 반환값 없음.
- Q.05 F. ('hello')는 문자열(괄호는 우선순위). 원소 하나 튜플은 ('hello',)처럼 심표 필수.
- Q.06 F. Transpose는 View. 수정하면 원본도 바뀜.
- Q.07 F. (3,)은 1차원(원소 3개). 행/열은 2차원부터. 3행1열은 (3,1).
- Q.08 F. $\inf - \inf = \text{nan}$.
- Q.09 T. Numpy에서는 &(AND), |(OR) 사용. 각 조건 괄호 필수.
- Q.10 F. data[조건]=값은 원본 직접 수정. 변수에 담으면 복사본.
- Q.11 T. 뒤에서 비교: $3==3 \rightarrow \text{OK}$.
- Q.12 F. radians()는 degree→radian. 반대는 degrees().
- Q.13 F. drop()은 새 DataFrame 반환. del df['열']이 원본 수정.
- Q.14 F. 중복 인덱스 시 DataFrame 반환. 1행이면 Series.
- Q.15 F. Pandas는 에러 대신 NaN 채움.
- Q.16 F. subplot에서는 set_xlabel() 사용.
- Q.17 T. apply()는 각 원소에 함수 적용 → 새 Series.
- Q.18 F. melt()는 Wide→Long. 반대는 pivot_table().
- Q.19 F. 선형 관계만 측정. 비선형은 $r=0$ 가능.
- Q.20 F. 서로 다른 관측 단위는 별도 테이블로 분리.
- Q.21 F. 표준편차 = $\sqrt{\text{분산}}$. 분산 = 표준편차².
- Q.22 F. p-value는 "H₀ 참일 때 이런 데이터 나올 확률".
- Q.23 F. lr 작으면 수렴 느려짐. 발산은 lr 클 때.
- Q.24 F. 반대! 혼재변수로 전체/하위그룹 결론 역전 가능.
- Q.25 T. $n \geq 30$ 이면 모집단 분포 무관하게 정규분포 근사.

PART 2 정답

- Q.26 ① 참조(슬롯) ② 스스로 변경
- Q.27 ① hash ② 해시 테이블
- Q.28 ① View ② Copy ③ .copy()
- Q.29 ① 오른쪽 끝 ② 같(동일) ③ 1
- Q.30 ① 라벨(이름) ② 정수 위치
- Q.31 ① 합집합 ② 교집합
- Q.32 ① 변수→열 ② 관측치→행 ③ 관측 단위→별도 테이블
- Q.33 ① 열 이름이 값 ② 한 열에 여러 변수 ③ 변수가 행+열 모두에
- Q.34 ① id_vars ② var_name ③ value_name
- Q.35 ① -1 ~ 1 ② 선형(linear)
- Q.36 ① Type I(α) ② Type II(β) ③ $1-\beta$
- Q.37 ① 95 ② 포함됨

Q.38 -(마이너스). gradient는 증가 방향 → 반대로 이동해야 최솟값.

Q.39 프로그래밍 실력, 수학/통계 지식, 도메인 전문성

Q.40 ① Ordinal(순서형) ② Dichotomous(이분형)

Q.41 ① 행(row) ② 열(column)

Q.42 count, mean, std, min, 25%, 50%(median), 75%, max

Q.43 P(A) / P(B) / 사전(Prior) / 사후(Posterior)

Q.44 Split → Apply → Combine

Q.45 ① 수직(vertical) ② 구간(bin) 개수

PART 3 정답

Q.46 -999. Transpose=View, t[0][2]=arr[2][0].

Q.47 (1, [10, 20, 30], 'hello'). 튜플은 참조 고정, 리스트 내부 변경 OK.

Q.48 [25. 35. 45.] (열별) | [20. 50.] (행별)

Q.49 [9, 16, 25]. if x>2 필터링(3,4,5) 후 제공.

Q.50 [1 0 3 0 5]. Boolean indexing 직접 대입=원본 수정.

Q.51 c=a+b에서 ValueError. (4,3)+(4,): 3 vs 4 불일치.

Q.52 [('a',85),('b',70),('c',92)]. zip은 짧은 쪽(3개)에서 끊김.

Q.53 'Science' | 'ecneicSataD' | 'DaSee'

Q.54 [4 6] | [3 7] | 10

Q.55 df.melt(id_vars=['Name'], var_name='Subject', value_name='Score')

Q.56 둘 다 True. d2(딕셔너리)가 빠름: O(1) vs O(n).

Q.57 tb_m['sex'] = tb_m['sex_and_age'].apply(lambda v: v[0])

Q.58 99999. NumPy 슬라이싱=View → 원본도 바뀜.

Q.59 6. 리스트 슬라이싱=Copy → 원본 안 바뀜.

Q.60 n_rad = n_day * 2 * np.pi / 86400

Q.61 df['diff'] = df['calc'] - df['actual'] / print(df['diff'].describe())

Q.62 plt.hist(df['value'], bins=50) / plt.axvline(x=100, color='red', linestyle='--')

Q.63 False | True | True

Q.64 d[[1,2,3]]에서 TypeError. 리스트는 unhashable → 키 불가.

Q.65 15. reduce 누적: (1+2)→3→6→10→15.

PART 4 정답

Q.66 평균=5.0 / 분산=(9+1+1+1+0+0+4+16)/8=4.0 / 표준편차= $\sqrt{4}$ =2.0

Q.67 $P(D|+) = (0.95 \times 0.02) / ((0.95 \times 0.02) + (0.10 \times 0.98)) = 0.019 / 0.117 \approx 0.162$ (16.2%)

Q.68 Beta(25,15). 평균 = 25/40 = 0.625

Q.69 $p(0.032) < \alpha(0.05) \rightarrow H_0$ 기각. "공정하지 않다."

Q.70 $1 - 0.95^{10} \approx 0.401$ (40.1%)

Q.71 $r = 1.0$. $Y=2X$ 이므로 완전 선형.

Q.72 P(둘다 딸|최소1딸) = $(1/4) / (3/4) = 1/3$

Q.73 $SE \approx 0.0158$ / CI=[0.494, 0.556]. 0.5 포함 → 기각 실패.

PART 5 정답

- Q.74** NumPy는 대용량용이라 복사 비용이 크므로 View 반환. 리스트는 메모리 비연속이라 Copy. Fancy/Boolean=Copy. 보호는 .copy().
-
- Q.75** 3원칙: 변수→열, 관측치→행, 관측단위→테이블. 소독 구간이 열 이름에 값으로 → 1번 위반. melt(id_vars, var_name, value_name)으로 해결.
-
- Q.76** 상관=함께 변하는 패턴. 인과=직접 유발. 제3 변수 가능. 예: 아이스크림↔익사(여름이 원인).
-
- Q.77** 유병률 0.01%, 정확도 99%여도 양성=실제 ~1%. 건강인이 많아 거짓 양성 > 진짜 환자.
-
- Q.78** p-value="H₀ 참일 때 극단적 데이터 나올 확률". 오해1: 효과 확률 아님. 오해2: 기각 실패≠H₀ 참.
-
- Q.79** lambda: 단순(v[0] 추출). 사용자함수: 복잡한 조건분기(get_age의 if/elif).
-
- Q.80** describe()로 mean/std/min/max 한번에 파악. 오차 원인: 모델 단순화 가정, 측정 오차, 외부 요인 미반영 등.
-